TÜBİTAK–2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI

Başvuru formunun Arial 9 yazı tipinde, her bir konu başlığı altında verilen açıklamalar göz önünde bulundurularak hazırlanması ve ekler hariç toplam 20 sayfayı geçmemesi beklenir (Alt sınır bulunmamaktadır). Değerlendirme araştırma önerisinin özgün değeri, yöntemi, yönetimi ve yaygın etkisi başlıkları üzerinden yapılacaktır.

ARAŞTIRMA ÖNERİSİ FORMU

2024 Yılı

1. Dönem Başvurusu

A. GENEL BİLGİLER

Başvuru Sahibinin Adı Soyadı: Sema TEMUR, Velat DİCLELİ
Araştırma Önerisinin Başlığı: Medikal Görüntülemede Yapay Zekâ Destekli Otomatik Raporlama Sistemlerinin Geliştirilmesi
Danışmanın Adı Soyadı: Dr. Öğr. Üyesi Buket TOPTAŞ
Araştırmanın Yürütüleceği Kurum/Kuruluş: Bandırma Onyedi Eylül Üniversitesi

ÖZET

Türkçe özetin araştırma önerisinin (a) özgün değeri, (b) yöntemi, (c) yönetimi ve (d) yaygın etkisi hakkında bilgileri kapsaması beklenir. Bu bölümün en son yazılması önerilir.

Özet

Medikal görüntüleme, hastaların tanı ve tedavi süreçlerinde kritik bir rol oynamaktadır. Radyolojik görüntüler, uzman hekimlerin hastalıkları doğru bir şekilde teşhis etmelerine ve uygun tedavi planları oluşturmalarına olanak tanır. Ancak, bu görüntülerin yorumlanması ve raporlanması zaman alıcı bir süreçtir ve uzmanlık gerektirir. Bu nedenle, otomatik rapor oluşturma sistemlerinin geliştirilmesi hem sağlık hizmetlerinin verimliliğini artırmak hem de hekimlerin üzerindeki yükü hafifletmek açısından büyük önem taşımaktadır.

Bu çalışmada, ClinicalBERT ve ClinicalGPT modellerinin önceden eğitilmiş evrişimli sinir ağı mimarileriyle entegre edilerek medikal görüntüler üzerinden otomatik rapor oluşturma sürecinin geliştirilmesi planlanmaktadır. Projede, radyolojik görüntülerin ve ilgili raporların olduğu veri setleri üzerinde çalışılacaktır. Elde edilen veriler, veri ön işleme aşamasında geçirilecek ve böylece görüntüler ve metinler modellere uygun hale getirilecektir. ResNet50 ve VGG19 mimarileri kullanılarak temizlenen radyolojik görüntülerden özellik çıkarımı yapılacaktır. Çıkarılan özellikler, metin verileriyle birleştirilerek ClinicalBERT ve ClinicalGPT modelleri ile işlenecektir. Eğitim sürecinde modelin performansı izlenecek ve yeni görüntüler üzerinden doğru raporlar üretilmesi sağlanacaktır. Son olarak, elde edilen otomatik raporlar kullanıcı dostu bir web ve mobil arayüz aracılığıyla sunulacaktır. Bu projenin sonunda ulusal bir makele, uluslararası bir bildiri ve proje ekibinin lisans bitirme tez çalışmalarının tamamlanması yaygın etki oluşturmaktadır. Ayrıca, radyolojik raporların otomatik oluşturulması için yapay zekâ tabanlı mobil ve web arayüzü de sağlık hizmetine sunulacaktır.

Anahtar Kelimeler: Medikal Görüntüleme, Otomatik Rapor Oluşturma, ClinicalBERT, ClinicalGPT

1. ÖZGÜN DEĞER

1.1. Konunun Önemi, Araştırma Önerisinin Özgün Değeri ve Araştırma Sorusu/Hipotezi

Araştırma önerisinde ele alınan konunun kapsamı ve sınırları ile önemi literatürün eleştirel bir değerlendirmesinin yanı sıra nitel veya nicel verilerle açıklanır.

Özgün değer yazılırken araştırma önerisinin bilimsel değeri, farklılığı ve yeniliği, hangi eksikliği nasıl gidereceği veya hangi soruna nasıl bir çözüm geliştireceği ve/veya ilgili bilim veya teknoloji alan(lar)ına kavramsal, kuramsal ve/veya metodolojik olarak ne gibi özgün katkılarda bulunacağı literatüre atıf yapılarak açıklanır.

Önerilen çalışmanın araştırma sorusu ve varsa hipotezi veya ele aldığı problem(ler)i açık bir şekilde ortaya konulur.

<u>Proje önerisinde ele alınan konunun kapsamı ve sınırları ile önemi:</u>

Bu projenin kapsamı, radyologların iş yükünü azaltmak ve daha iyi tıbbi kalite sağlamak için, radyolojik görüntülerine dayalı olarak doğru metin açıklamalarını otomatik olarak üreten bir sistem tasarımı ile ilgilidir. Radyolojik görüntüler, vücudun içyapısını görünür hale getiren ve doktorların hastalıkları teşhis etmesine, izleme yapmasına veya tedavi süreçlerini planlamasına yardımcı olan görüntülerdir. Radyologlar rutin olarak normal ve anormal semptomlarla ilgili tıbbi durumları teşhis etmek için bu görüntüleri yorumlar ve radyolojik raporları oluştururlar. Radyoloji raporları, tanı bulgularını iletmede ve hasta bakımını yönlendirmede oldukça önemlidir. Bu raporlar, radyolog ve hastayı sevk eden doktor arasında önemli bir iletişim aracıdır ve hasta için önemli bilgileri barındırır. Ancak, radyolojik raporların oluşturulması genel olarak zahmetli ve zaman alıcı bir süreçtir. Raporun doğru yorumlanması, radyoloğun bilgi birikimine, dikkatine ve tecrübesine bağlı olarak hataya açıktır [1]**.** Radyolojik görüntü raporlarının otomatik olarak üretilmesi ile yanlış tanı ve teşhisler önlenebilir, hasta bakımının kalitesi korunarak radyologların iş yükü azaltılabilir.

Radyolojik raporların otomatik olarak üretilmesi için son zamanlarda popüler bir konu haline gelmiş ve bu alanda yapılan çalışmalar artmıştır[2] [3] [4].

Radyolojik rapor genel olarak iki bölümden oluşmaktadır. İlk bölüm, radyolojik görüntülerde gözlemlenen bulguların ayrıntılı olarak anlatıldığı ve teknik terimlerin kullanıldığı bölümdür. Bu bölüm hem görüntüleme sonuçlarındaki normal bulguların hem de dikkat çeken anormal bulguların yer aldığı kısımdır. [5]'de de belirtildiği gibi tıbbi görüntü raporlarının özellikle anormal bulgular konusunda yüksek doğrulukla rapor üretebilmesi, algoritmaların performansının artırılmasını gerektirir. Şekil-1'de bir radyolojik göğüs görüntüsü gösterilmektedir. Bu görüntünün rapor kısmında, sağ üst lobda 11 mm'lik stabil bir nodül, trakeanın orta hattında normal pozisyonu, pnömotoraks ve plevral efüzyon yokluğu, normal kalp boyutu ve omurgada tekrar gözlemlenen sindesmofit (kemik çıkıntısı) belirtilmiştir. Raporun ikinci bölümünde, radyolojik görüntünün saklanma şekli ve dosya adı belirtilmiştir. Şekil 1'de, 'Image_path' alanı, .png uzantılı radyolojik görüntünün dijital ortamda saklanan ismini göstermektedir.

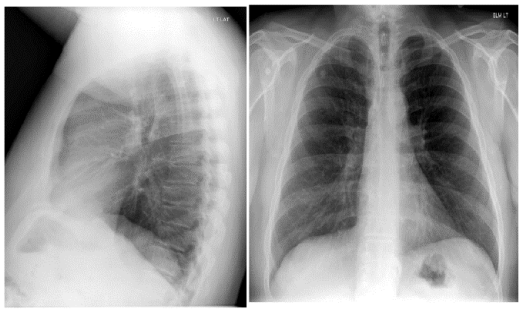

Report:

Well circumscribed 11 mm right upper lobe nodule, unchanged appearance from previous examination 7 years ago. The trachea is midline. Negative for pneumothorax, pleural effusion. The heart size is normal. Redemonstrated syndesmophyte.

Image_path:

["CXR3655_IM-1817/0.png", "CXR3655_IM-1817/1.png"]

Şekil -1 Örnek bir radyoloji raporu [6]

Projenin sınırları, öncelikle veri seti dengesizliği, veri çeşitliliğinin kısıtlı olması ve tıbbi raporların doğrulama zorlukları etrafında şekillenmektedir [7]. Veri setindeki anormal ve normal görüntülerin sayısındaki dengesizlik, modelin tüm senaryolara genelleme yapma kabiliyetini sınırlar. Ayrıca veri çeşitliliğinin azlığı, medikal görüntülerdeki anormal ve normal görüntülerin ayırt ediciliğinin az olması modelin farklı vakaları öğrenmesini ve başarılı bir şekilde yorumlamasını güçleştirir. Bu durumlar, özellikle karmaşık tıbbi koşullarda modelin performansını olumsuz yönde etkileyebilmektedir. Tıbbi raporların doğruluğu, dikkate alınması gereken önemli bir sınırlayıcı faktördür. Bu raporların oluşturulması, uzman bir doktorun uzun yıllar süren deneyimlerine dayanır. Ayrıca, her bir uzman doktorun radyolojik görüntülere yapacağı yorum ve teşhis farklılık gösterebilir. Eksik ya da hatalı raporların modelin eğitiminde kullanılması, modelin güvenilir sonuçlar üretmesini daha da zorlaştırabilir. Son olarak, modelin eğitimi için gerekli olan bilgi işlem kaynaklarının sınırlı olması, modeli tam kapasiteyle eğitme sürecinde bir diğer zorluk olarak karşımıza çıkmaktadır.

Literatürün Eleştirisel İncelenmesi:

Literatür incelemeleri, tıbbi görüntü raporlamasının tıbbi görüntüleme araştırmalarında önemli bir alan olduğunu ortaya koymaktadır. Bu süreç, tıbbi görüntü verilerini kullanarak hasta durumu hakkında açıklamalar ve teşhis önerileri içeren yapılandırılmış doğal dil raporları oluşturmayı hedeflemektedir. Tıbbi karar süreçlerini hızlandırma ve hata payını azaltma gibi potansiyel faydalarından dolayı, bu alan literatürde büyük ilgi görmekte ve aktif olarak araştırılmaktadır.

Jing ve arkadaşlarının [8] yaptığı çalışma otomatik medikal görüntü raporu üretme konusunda yapılan çalışmalardan biridir. Önerilen yöntemde, Co-attention mekanizması kullanarak uzun cümleler ve çeşitli başlıklar üretilmeye çalışılmıştır. Görüntülerden özellik çıkarımı için Visual Geometry Group (VGG19) [9] modeli kullanılmıştır. Uzun cümleler üretmek için Hiyerarşik Uzun Kısa Süreli Bellek ağı (Hierarchical Long Short-Term Memory- LSTM) [10] kullanılmıştır. Bu çalışma IU X-ray veri setini kullanarak radyoloji görüntülerini paragraf şeklinde üretmede çok iyi sonuçlar gösterse de oluşturulan paragraflarda tekrarlayan cümlelere sahiptir ve paragraf içindeki cümleler birbirleriyle uyum sağlayamamıştır. BLEU 1-2-3-4 metriklerinde 0.517, 0.386, 0.306 ve 0.247, METEOR metriğinde 0.217, ROUGE-L metriğinde 0.447 ve CIDEr metriğinde 0.327 başarı değerlerini almışlardır.

Diğer bir çalışmada [11] ise Evrişimli Sinir Ağı (Convolutional Neural Network- CNN) ve Hiyerarşik LSTM mimarisini ve aynı zamanda Attention mekanizmasını da kullanarak oluşturulan radyolojik rapordaki cümlelerin aralarında

uyum olmasını sağlamaya çalışmışlardır. Ortaya çıkan sonuç raporunun eğitim veri setinden daha farklı cümleler içerdiği görülmüştür. BLEU-1, BLEU-2, BLEU-3, BLEU-4, METEOR ve ROUGE-L metriklerinde sırası ile 0.464, 0.358, 0.270, 0.195, 0.274, 0.366 başarı değerlerini almışlardır.

Wang ve arkadaşlarının çalışmasında ise [12] IU X-ray veri seti kullanılmış ve cümle-görüntü gömülü ağ (TieNet) adında bir çoklu seviye Attention içeren bir Convolutional Neural Network- Recurrent Neural Network- Long Short Term Memory (CNN-RNN-LSTM) mimarisi kullanılmıştır. CNN modeli olarak ResNet50[13] kullanılmıştır. Birden fazla RNN kullanmanın hastalıkların özelliklerinin daha iyi biçimde öğrenilmesini ve kaliteli rapor yazılmasını sağladığı görülmüştür. BLEU 1-2-3-4 metriklerinde sırası ile 0.2860, 0.1597, 0.1038, 0.0736 değerlerini almışlardır. METEOR ve ROUGE-L metiklerinde ise 0.1076 ve 0.2263 başarı değerlerini almışlardır.

Diğer bir çalışmada ise Omar ve arkadaşları [14] CDGPT2 (Chest X-ray dataset finely tuned with GPT2) adında otomatik radyoloji görüntülerinden rapor oluşturan bir mimari duyurmuşlardır. Chest X-ray adlı veri seti çalışmada kullanılmıştır. Oluşturdukları Chexnet modeli Encoder olarak çalışarak görüntülerden özellik çıkarımını sağlamıştır. Rapor oluşturma kısmında ise Generative Pretrained Transformer-2 (GPT2)[15] modeli kullanılmıştır. Oluşturulan model hiyerarşik olmayan modelleri değerlendirme metriklerinde geçse de Hiyerarşik Tekrarlayan Modelleri [Hierarchical Recurrent Models] geçememiştir. BLEU-1, BLEU-2, BLEU-3, BLEU-4, METEOR ve ROUGE-L metriklerinde sırası ile 0.387, 0.245, 0.166, 0.111, 0.164 ve 0.289 performans değerlerini almışlardır.

Navdeep ve arkadaşları [16] Bidirectional Encoder Representations from Transformer (BERT) [17] modelleri arasında bir analiz gerçekleştirmişlerdir. BioBERT [18] , ClinicalBioBert [19]ve DistilBERT [20] modelleri radyoloji görüntülerinden rapor elde edilmesi konusunda eğitilip karşılaştırılmıştır. Analizlerin yapılması için pre-trained CNN modeli VGG19 [9] kullanılmıştır. Sonuçlar DistilBERT[20] modelinin diğerlerine göre rapor üretmekte daha iyi olduğunu göstermiştir. Ayrıca bu çalışmada CNN+ Hiyerarşik LSTM mimarisini DistilBERT[20] ile kullanarak başarı metriklerinde BLEU-1 = 0.772, BLEU-2 = 0.770, BLEU-3 = 0.768, BLEU-4 = 0.767, CIDEr = 0.5563 ve ROUGE-L = 0.897 değerlerini elde etmişlerdir.

Diğer bir çalışmada [21] radyoloji görüntülerinden rapor oluşturmak için veri seti olarak IU X-ray kullanılmıştır, Encoder olarak CNN modeli olan VGG16 [9] mimarisi kullanılmıştır. Görüntülerin çıkarılan özellikleri bir Attention mekanizmasından geçirilmiş ve Decoder olarak kullanılan LSTM'e [10] verilmiştir. Attention kullanmalarındaki sebep ise görsellerdeki ilgi alanına ait olan ve maksimum bilgiye sahip olunabilecek kısımlara odaklanılmasını sağlamaktır. Bu çalışmada birden çok model karşılaştırılmıştır ve kurulan bu mimari diğerlerine göre değerlendirme metriği olan BLEU-4 metriğinde 0.153 başarı performansı göstermiştir.

Tsaniya ve arkadaşları [22] Decoder olarak BERT [17], özellik çıkarımında kullanmak için ise CNN ve Multi-Head Attention mimarisini kullandıkları bir otomatik rapor oluşturma çalışması üzerinde çalışmışlardır. Veri seti olarak IU X-ray kullanılmıştır. Bu yapılan çalışmada oluşturulan modelin değerlendirme metriklerinde çok iyi sonuç aldığını, önceden bu alanda yapılmış olan çalışmalardaki modelleri geri planda bırakabileceği açıklanmıştır. Oluşturulan model BLEU metriğinde 0.412 başarı puanı alarak temel alınan modelden %15 daha iyi sonuç vermiştir.

Divya ve arkadaşları [23] IU X-ray ve MIMIC-CXR veri setlerini ayrı ayrı kullanarak rapor oluşturma çalışması gerçekleştirmişlerdir. Görsellerden özellik çıkarımı için SSVE adını verdikleri bir mimari kullanılmış ve bu görsellerden çıkarılan özellikler veri setinde bulunan örnek raporlarla birlikte Memory Transformer'a [24] verilmiştir. Transformer [25] kullanmalarındaki sebep ise geleneksel yöntemlerde sıklıkla kullanılan RNN, LSTM[10], Hiyerarşik LSTM gibi mimarilerin uzun paragraf halinde rapor oluşturmalarında başarısız performans gösterdiklerini iddia etmeleridir. Yaptıkları çalışma sonrasında IU X ray veri seti kullanılarak yapılan çalışma sonucunda BLEU 1-2-3-4 ve METEOR metriklerinde sırasıyla 0.492, 0.321, 0.233, 0.180, 0.203 değerlerini almışlardır. MIMIC-CXR veri seti ile yapılan çalışma sonucunda ise BLEU 1-2-3-4 ve METEOR metriklerinde sırasıyla 0.373, 0.230, 0.161, 0.112, 0.162 değerlerini almıştır.

Literatürde bu alanda yapılan çalışmalarda CNN, RNN veya LTSM [10]modellerinin birleşimi olan geleneksel mimarilerin yanı sıra Transformer [25] mimarilerini de içermektedir [26]. Ancak bu çalışmaların bazı sınırlamaları bulunmaktadır. İlk olarak, üretilen raporlarda tekrarlayan cümleler ve paragraf içi uyumsuzluklar sıkça karşılaşılan sorunlardandır. Ayrıca, BLEU, METEOR ve ROUGE-L gibi metriklerde elde edilen başarı oranları, modellerin performansının halen geliştirilmesi gerektiğini göstermektedir. Özellikle tıbbi terimlerin karmaşık yapısına uygun, doğal dil işleme modelleri yetersiz kalmaktadır. Bunun yanı sıra, kullanılan veri setlerinin sınırlılığı, modellerin genelleme yeteneğini olumsuz etkilemektedir. Bu nedenle, daha gelişmiş modeller ve genişletilmiş veri setleri ile bu alanda daha başarılı sonuçlar elde edilmesi beklendiği için bu alan aktif bir çalışma alanıdır.

<u>Projenin özgün değeri:</u>

Bu çalışmada, doğal dil işleme (Natural Language Processing - NLP) alanında başarı göstermiş iki model, ClinicalBERT [27] ve ClinicalGPT [28] , önceden eğitilmiş CNN modelleri ile entegre edilerek tıbbi görüntüler

üzerinden otomatik rapor oluşturulması hedeflenmektedir. Çalışma kapsamında, ClinicalBERT ve ClinicalGPT modellerinin performansları kapsamlı bir biçimde değerlendirilecektir. Bu değerlendirmede doğruluk, anlamsallık ve kapsayıcılık gibi performans metrikleri dikkate alınarak karşılaştırma yapılacaktır. Elde edilen sonuçlar doğrultusunda hem teknik hem de pratik uygulanabilirlik açısından en yüksek başarıyı gösteren model belirlenecektir. Seçilen model, kullanıcı dostu bir web ve mobil arayüz geliştirilerek, sağlık hizmetlerinde yapay zekâ tabanlı tıbbi raporlama süreçlerine katkı sağlamak üzere kullanılacaktır. Bu sayede, klinik uygulamalarda yapay zekâ destekli raporlama süreçlerinin hızlandırılması ve kolaylaştırılması amaçlanmaktadır.

1.2. Amaç ve Hedefler

Araştırma önerisinin amacı ve hedefleri açık, ölçülebilir, gerçekçi ve araştırma süresince ulaşılabilir nitelikte olacak şekilde yazılır.

Amaçlar:

1. ClinicalBERT[27] ve ClinicalGPT'nin [28] mimarilerini kullanarak tıbbi görüntüler üzerinde otomatik rapor oluşturma sürecini geliştirmek.
2. Farklı yapay zekâ ve makine öğrenmesi modellerinin tıbbi raporlama süreçlerinde uygulanabilirliğini incelemek.
3. Klinik uygulamalarda yapay zekâ destekli çözümlerle sağlık hizmetlerinde verimliliği artırmak.

Hedefler:

1. ClinicalBERT[27] ve ClinicalGPT[28] modellerinin, önceden eğitilmiş CNN ile entegre edilmesi.
2. Modellerin doğruluk, anlamsallık, kapsayıcılık gibi performans metrikleri ile karşılaştırılması.
3. Hem teknik performans hem de pratik uygulama açısından en yüksek başarıyı sağlayan modelin belirlenmesi.
4. Seçilen modelin kullanıcı dostu bir web ve mobil arayüz ile desteklenmesi.
5. Yapay zekâ destekli tıbbi raporlama süreçlerinin sağlık hizmetlerinde kolaylaştırılması ve hızlandırılması.

2. YÖNTEM

Araştırma önerisinde uygulanacak yöntem ve araştırma teknikleri (veri toplama araçları ve analiz yöntemleri dahil) ilgili literatüre atıf yapılarak açıklanır. Yöntem ve tekniklerin çalışmada öngörülen amaç ve hedeflere ulaşmaya elverişli olduğu ortaya konulur.

Yöntem bölümünün araştırmanın tasarımını, bağımlı ve bağımsız değişkenleri ve istatistiksel yöntemleri kapsaması gerekir. Araştırma önerisinde herhangi bir ön çalışma veya fizibilite yapıldıysa bunların sunulması beklenir. Araştırma önerisinde sunulan yöntemlerin iş paketleri ile ilişkilendirilmesi gerekir.

Bu projede, radyolojik göğüs görüntülerinden otomatik rapor üretimi amacıyla görüntü işleme ve NLP teknikleri kullanılacaktır. Veri toplama süreci, radyolojik görüntülerin ve bu görüntülere ait raporların elde edilmesi, etik onaylı bir veri seti üzerinden işlenmesini kapsar. Çalışmada kullanılacak temel yöntemler, ilgili literatüre dayalı olarak beş aşamadan oluşmaktadır. Bu aşamalar şöyledir:

İlk aşama, veri önişleme aşamasıdır. Bu aşamada hem radyolojik görüntülerin hem de bu görüntülere ait raporların temizlenmesi ve düzeltilmesi yapılmaktadır. Görüntülerdeki boyut ayarlama, raporlarda bulunan anlamsal tutarlılık ve dilbilgisel doğruluk sağlanır. Bu süreç, modelin daha tutarlı ve doğru sonuçlar üretmesini amaçlamaktadır.

İkinci aşama, özellik çıkarım aşamasıdır. Bu aşamada, ön işlenmiş radyolojik görüntüler, önceden eğitilmiş transfer öğrenme modelleri (örneğin, ResNet, VGG19 gibi CNN tabanlı mimariler) ile işlenir. Bu süreç sonucunda, görüntülerdeki önemli ve anlamlı özellikleri temsil eden bir özellik matrisi elde edilmektedir.

Üçüncü aşama**,** veri entegrasyonu ve model girişi aşamasıdır. Bu aşamada, ilk aşamada önişlenmiş radyolojik rapor verileri ile ikinci aşamada elde edilen özellik vektörleri, Transformer [25]mimarisine girdi olarak verilir. Burada amaç, metin ve görüntü verilerini birleştirerek, rapor oluşturma sürecinde daha güçlü bir temsil elde etmektir. Transformer [25] modeli, bu iki farklı veri kaynağını kullanarak daha doğru ve detaylı tıbbi raporlar üretmeyi hedefler.

Dördüncü aşama, Transformer [25] mimarisinin eğitilmesi ve raporlama aşamasıdır. Bu aşamada, model, geniş çaplı medikal verilerle eğitilerek hem metinsel hem de görsel girdilere dayalı raporlar üretir. Eğitim süreci boyunca modelin doğruluğu, kaybı ve diğer performans metrikleri izlenir, böylece raporların güvenilirliği artırılır.

Son aşama, sonuçların sunulma aşamasıdır. Elde edilen raporlar, kullanıcı dostu bir web arayüzü ve mobil uygulama aracılığıyla hastalara sunulur. Bu aşamada, hastaların hızlı ve etkili bir şekilde tıbbi raporları görüntüleyebilmesi ve kullanabilmesi amaçlanmaktadır. Bu aşamalara ait detaylı bilgiler bu bölüm altında alt başlıklar olarak verilmiş ve önerilen yöntemin genel şeması Şekil-2'de sunulmuştur. Tüm aşamaların detayları bu bölümde alt başlıklar olarak verilmiştir.

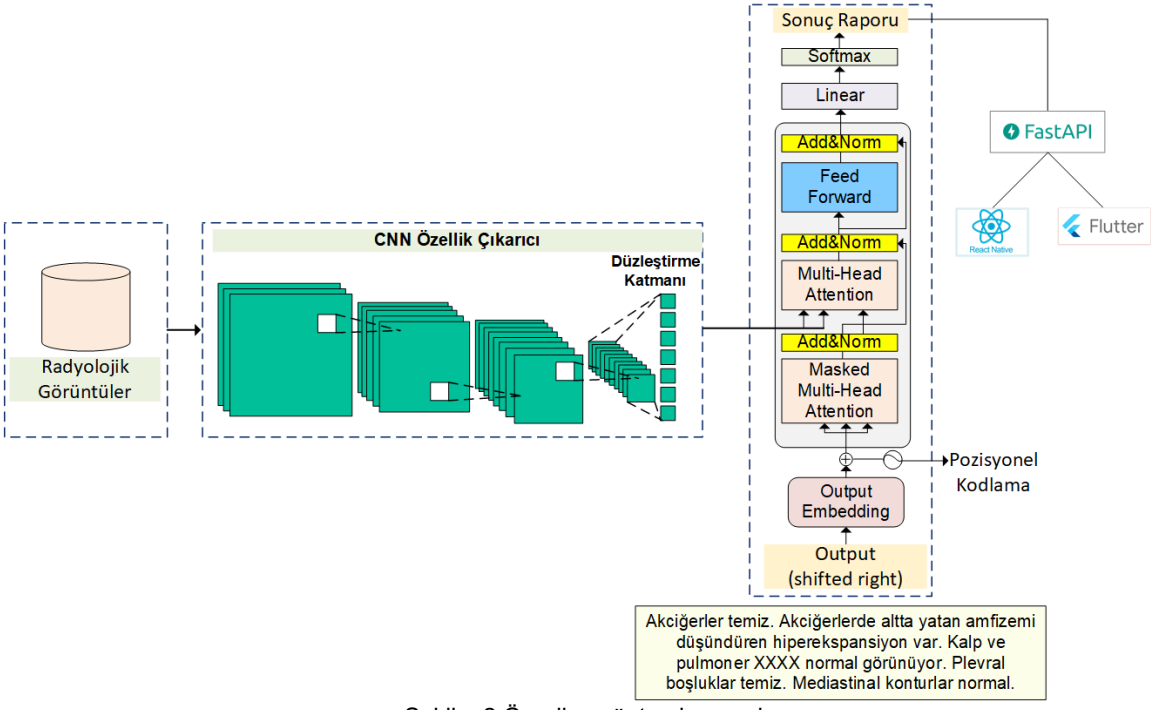

Şekil – 2 Önerilen yöntemin genel şeması

Veri Ön İşleme

Ön işlem, radyolojik görüntülerin yeniden boyutlandırılması ve medikal raporların anlamsal doğruluğunun arttırılması için uygulanan bir dizi adımı içerir. Bu aşamada, radyolojik görüntülerden fazlalık veriler temizlenirken, raporlardaki yazım hataları ve eksik bilgilerin düzenlenmesi sağlanır. Yöntemin bu aşaması iki

ayrı adımdan oluşmaktadır. Bu adımlar sırasıyla radyolojik görüntülerin işlenmesi ve metin ön işleme aşamalarıdır.

Radyolojik görüntülerin işlenmesi: Raporu bulunmayan radyolojik görüntülerin veri setinden çıkarılması, analiz sürecinin doğruluğunu artırmak için önemli bir adımdır. Bu işlem, modelin yalnızca anlamlı ve tamamlayıcı bilgiye sahip görüntülerle çalışmasını sağlayarak, gürültü oluşturan veya eksik verilerden kaynaklanan hataları azaltır. Ardından, görüntülerin boyutlarının tutarlı hale getirilmesi, modelin her görüntüyü aynı formatta işleyebilmesi için kritik bir adımdır. Bu bağlamda, her bir radyolojik görüntünün boyutu CNN mimarilerinin girdi boyutuna göre yeniden biçimlendirilir. Boyutlandırma işlemi, görüntülerin yüksek çözünürlüğünü ve ayrıntılarını koruyarak gerçekleştirilir; böylece model hem detay kaybı yaşamadan hem de sabit boyutta verilerle çalışarak daha iyi sonuçlar üretir. Bu standart boyutlandırma, ile model her görüntüyü tutarlı bir giriş verisi olarak kabul eder ve eğitim süreci daha verimli hale gelir.

Metin ön işleme: Radyolojik raporların doğal dil işleme modellerine uygun hale getirilmesi için gerçekleştirilen bir dizi sistematik adımdan oluşur. Bu sürecin ilk aşamasında, anlam taşımayan ya da veri gürültüsüne sebep olan semboller, özel karakterler ve gereksiz noktalama işaretleri metinden temizlenir. Bu işlem, modelin yalnızca anlamlı bilgiye odaklanmasını sağlar.

Ardından, büyük harfler küçük harflere dönüştürülerek, harf farklılıklarının modeller üzerinde gereksiz bir karmaşaya neden olması engellenir. Bu dönüşümü, anlamsal olarak sınırlı katkı sağlayan sayıların ve fazlalık oluşturan verilerin temizlenmesi takip eder. Ayrıca, dilde yaygın olarak kullanılan ancak anlam açısından sınırlı bilgi sunan durdurma kelimeleri (stopwords) metinden ayıklanır. Bu adım, modelin metin içindeki anlamlı bilgilere daha iyi odaklanmasını sağlar.

Metin ön işlemenin bir diğer önemli bileşeni, kelimelerin köklerine indirgenmesi (stemming) veya çekim eklerinden arındırılması (lemmatization) sürecidir. Bu sayede, aynı kökten türeyen ancak farklı biçimlerde çekimlenmiş kelimeler tek bir forma dönüştürülür. Örneğin, "lungs" (akciğerler) kelimesinin "lung" (akciğer) formuna indirgenmesi, modelin varyasyonları daha iyi anlamlandırmasına olanak tanır.

Bu işlemler tamamlandıktan sonra, metin tokenizasyon adı verilen bir işlemle kelime birimlerine ayrılır. Böylece metin, model tarafından işlenebilecek anlamlı kelime gruplarına bölünmüş olur. Son olarak, her bir kelime, belirli bir kelime dağarcığına (vocabulary) göre atanmış benzersiz bir kimlik (ID) ile eşleştirilir. Bu aşama, metinleri modelin sayısal olarak işleyebilmesini sağlayarak, doğal dil işleme sürecinin tutarlı ve verimli bir şekilde ilerlemesine katkıda bulunur.

Son aşamada ise, metinlerin uzunluklarını sabitlemek için kısa metinlere padding (doldurma) uygulanır. Padding işlemi, daha kısa metinlerin standart uzunluğa ulaşması için eklenen 0 değeriyle gerçekleştirilir. Bu adım, özellikle Transformer [25]modelleri (örneğin, GPT-2, BERT) gibi modellerin metinleri eşit uzunlukta veriler üzerinden analiz etmesini sağlar. Böylelikle, radyolojik raporlar hem doğruluk hem de tutarlılık açısından daha başarılı ve güvenilir sonuçlar üretecek şekilde işlenmiş olur.

Bu adımlar, metni daha yalın ve işlenebilir hale getirir ve modelin anlamlı özelliklere odaklanmasını kolaylaştırır. Metin ön işleme sürecine ait işlemler Şekil-3'de görsel olarak sunulmuştur.

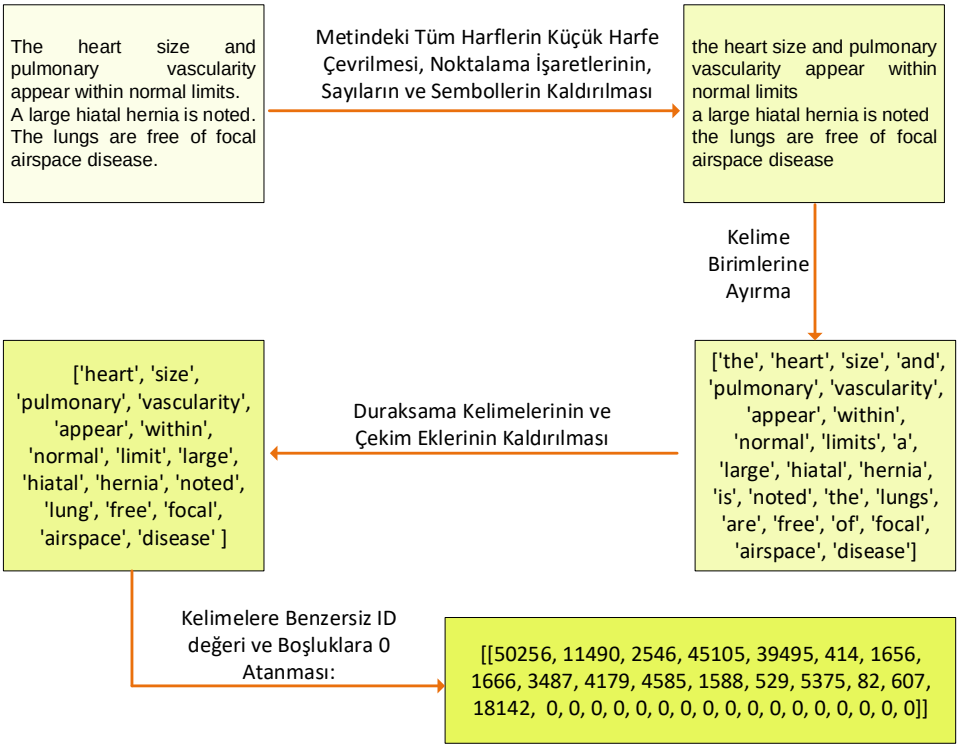

Şekil -3 Metin ön işleme akış diyagramı

Önceden Eğitilmiş CNN Modelleri ile Özellik Çıkarımı:

Radyolojik görüntülerden anlamlı özellikler çıkarmak amacıyla, önceden eğitilmiş CNN mimarileri kullanılacaktır. Bu çalışmada, literatürde özellik çıkarımında başarı elde etmiş olan iki ResNet ve VGG16 mimarilerinin kullanılması planlanmıştır. Bu mimariler, özellik çıkarma ve otomatik rapor oluşturma çalışmalarında gösterdikleri üstün performanstan [26] dolayı bu proje çalışmasında da tercih edilmiştir. ResNet mimarisi [13] 2015 yılında CNN mimarisi kategorisinde hata oranı en düşük olarak çıkan ve birinci olan bir mimari iken, VGG16 [9] mimarisi ise 2014 yılında CNN mimarisi alanında hata oranının düşüklüğü ile ikinci olan bir mimaridir [29].

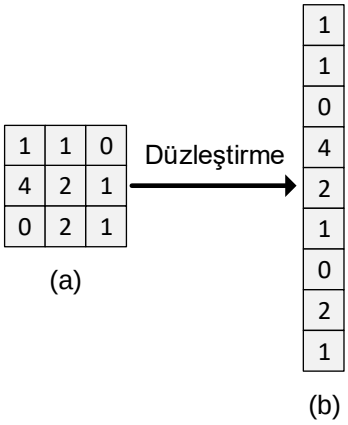

Şekil -4 Düzleştirme katmanı

Önceden eğitilmiş CNN mimarilerinden çıkarılan özellikler, CNN mimarisinin düzleştirme katmanından elde edilir. Bu süreç Şekil 4'te [30], görsel olarak sunulmuştur. Bu şekilde, derin öğrenme mimarisinin havuzlama katmanından gelen bilgi, sinir ağına giriş olarak verilmeden önce vektör haline getirilir. Bu işleme düzleştirme adı verilir. Şekil 4 (a)'da önceki katmandan gelen özellik matrisi bulunmaktadır. Şekil 4 (b)'de ise bu matrisin

vektör olarak temsil edilmesi gösterilmiştir. Düzleştirme işlemi, elde edilen özelliklerin Transformer[25] modelinin Decoder kısmına metin ile birlikte girdi olarak hazırlanmasına olanak tanır. Bu yöntemle, evrişimsel katmanlardan çıkarılan karmaşık görsel özellikler metin verisiyle birleştirilerek daha etkin bir şekilde işlenebilmektedir. Böylece, hem görüntü hem de metin verilerinin entegrasyonu ile modelin genel performansı artırmaktadır.

Veri Entegrasyonu ve Transformer Modelleri: Radyolojik görüntülerden çıkarılan özelliklerin ön işleme tabi tutulmuş metinlerle birleştirilmesi, tıbbi rapor üretiminde daha etkili sonuçlar elde etmek amacıyla kritik bir adım olarak öne çıkmaktadır. Radyolojik görüntü özellikleri ve radyolojik rapor metinlerinin birleştirilmesi, tıbbi raporların oluşturulmasında daha derinlemesine analiz yapılmasına ve anlam çıkarma kapasitesinin artmasına olanak tanır. Bu birleşme sürecinde, transformer tabanlı modellerden, ClinicalBERT [27] ve ClinicalGPT [28] modeli proje kapsamında kullanılması planlanmaktadır.

ClinicalBERT [27] model, BERT [17] modelinden farklı olarak klinik metin ile eğitilmiştir. Bu modele ihtiyaç duyulmasının sebebi tam olarak medikal bilgiler ile eğitilmiş model ile hastaların hastaneye geri yatış durumlarını tahmin etmek içindir [27] . ClinicalBERT [27] , çeşitli hastalıklara ilişkin 1.2 milyar sözcükten eğitilen tıbbi metinlerden bilgi çıkarma ve metin üretimi gibi önemli görevlerde etkili sonuçlar elde etmektedir [30].

ClinicalGPT [28] ise, klinik vakalar için optimize edilmiş ve tasarlanmış ileri düzey bir transformer modelidir. Bu model, tıbbi kayıtlar, uzmanlık alanına özgü bilgiler ve çok aşamalı danışma diyalogları gibi çeşitli tıbbi veri setleri üzerinde dikkatlice ince ayar yapılarak geliştirilmiştir. ClinicalGPT'nin amacı, sağlık hizmetlerinde bilgi desteği sağlamak ve klinik tabanlı metin üretimi yapmaktır [28].

Bu kapsamda, radyolojik görüntülerden çıkarılan özelliklerin ön işleme tabi tutulmuş metinlerle birleştirilmesi, ClinicalBERT [27] ve ClinicalGPT [28] gibi Transformer [25] tabanlı modellerin etkili bir şekilde kullanılmasını sağlamakta ve tıbbi veri işleme süreçlerinin verimliliğini artırmaktadır.

Eğitim ve Tahmin Aşaması: Modelin eğitim süreci, radyolojik görüntülerin analiz edilmesinde kritik bir öneme sahiptir. Eğitim aşamasında, öncelikle radyolojik görüntülerden çıkarılan özellikler önişleme uygulanmış metin raporları ile birleştirilir. Bu birleşik veri seti, ClinicalBERT [27] ve ClinicalGPT [28] gibi Transformer [25] tabanlı modellerin eğitimi için kullanılır. Model, tıbbi terminolojiyi ve dil yapılarını anlamada derin öğrenme tekniklerinden yararlanarak görüntü verilerinden bilgi çıkarma ve metin üretme yeteneklerini geliştirir.

Modelin eğitim süreci tamamlandıktan sonra, yeni bir radyolojik görüntü verildiğinde tahmin işlemi aşağıdaki adımları izleyerek gerçekleştirilir:

- İlk olarak, yeni görüntü, ResNet50 [13] veya VGG19 [9] gibi CNN modelleri kullanılarak işlenir. Bu işlem, görüntüdeki kritik görsel özelliklerin çıkarılmasını sağlar. CNN modelleri, katmanlar arasında hiyerarşik bir yapı ile çalışarak görüntülerdeki belirgin desenleri ve anomalileri tanımlamada yüksek başarı gösterir.
- Elde edilen görsel özellikler, daha sonra ClinicalGPT [28] veya ClinicalBERT [27] modellerine iletilir. Bu aşamada, görsel verilerden elde edilen bilgiler kullanılarak görüntüde tespit edilen anomalilere uygun tıbbi rapor metni üretilir.

Değerlendirme Aşaması: Metin üretiminde, oluşturulan metinlerin kalitesini ve doğruluğunu ölçmek için çeşitli değerlendirme metrikleri kullanılmaktadır. Bu projede kullanılması planlanan değerlendirme metrikleri BLEU, METEOR, CIDEr ve ROUGE-L'dir.

<u>Bilingual Evaluation Understudy (BLEU)</u> [31] makine çevirisinin başarısını ölçmek için oluşturulmuştur. Ortaya çıkan tahmini rapor sonucu dizisi ile referans dizi arasındaki yazışmayı ölçer. BLEU değeri ne kadar yüksekse referans dizisine o kadar yaklaştığı anlamına gelir. BLEU n-gram (n kelimelik alt diziler) için kesinlik değeri ölçer ve aşırı kısa cümlelere *BP* adında bir katsayı cezası uygular. Aşağıdaki matematiksel ifadede BLEU metriğinin hesaplanması gösterilmiştir.

$$\mathrm{pn} = \frac{\text{Number of n−grams in candidate that match reference}}{\text{Total number ofn−grams in candidate}} \qquad (1)$$

$$BP = \begin{cases} 1, & if\ c > r \\ e^{(1-\frac{r}{c}}, & if\ c \leq r \end{cases}, \quad \mathrm{BLEU} = BP.\exp(\textstyle\sum_1^N w_n \log pn) \qquad (2)$$

Denklem (1)'de *pn*, *n* kelimeden oluşan alt diziler için kesinlik değerini (precision) hesaplar. Denklem (2)'de *BP* aşırı kısa cümleler için bir ceza katsayısıdır. *c* parametresi aday dizilerin uzunluğu, *r* parametresi referans dizilerin uzunluğudur. w_n *n*-gramlar için bir ağırlığı temsil etmektedir.

Metric for Evaluation of Translation with Explicit Ordering (METEOR) [32] insan ve makine tarafından oluşturulmuş yazıların aralarındaki ilişkiyi cümle bazında değerlendirmek için geliştirilmiştir. Kesinlik ve duyarlılık değerlerinin harmonik ortalamasını (F_{mean}) kullanarak hesaplama yapılır[33].Ayrıca hesaplamada aday dizilerde kötü kelime sıralaması olduğunda uygulanan bir penaltı cezası da vardır. Aşağıdaki matematiksel ifadede METEOR metriğinin hesaplanması gösterilmiştir.

$$P = \frac{\mathrm{m}}{\text{length of candidate}}, R = \frac{m}{length\ of\ reference} \quad (3)$$

$$F_{mean} = \frac{10PR}{R+9P} \quad (4)$$

$$Pen = 0.5 . \frac{\#\text{chunks}}{m} \quad (5)$$

$$\text{METEOR} = F_{mean} . (1 - Pen) \quad (6)$$

Denklem (3)'de öncelikle kesinlik (P) ve duyarlılık (R) değerleri hesaplanır. *m* değeri referans dizi ile aday dizi arasındaki kelime eşleşme sayısıdır. Denklem (4)'de kesinlik ve duyarlılık değerleri kullanılarak harmonik ortalama hesaplanır. Denklem (5)'de *Pen* parametresi hesaplanmıştır. *Pen* parametresi bir ceza katsayısıdır. Bu ceza katsayısı zayıf kelime sırasına sahip olan aday dizilere uygulanır. *#chunks* parametresi referans dizi ile aday dizi arasındaki aynı sırada eşleşmiş kelime gruplarının sayısıdır.

Consensus-based Image Description Evaluation (CIDEr) [34] resim açıklaması için geliştirilmiştir. Bu metrik frekans-ters belge frekansı (TF-IDF) kullanarak üretilmiş açıklama ile referans açıklama arasındaki kosinüs benzerliğini ölçer. Yüksek CIDEr değeri önemli kelimelerin kapsandığını gösterir. Aşağıdaki matematiksel ifadede CIDEr metriğinin hesaplanması gösterilmiştir.

$$\mathrm{TF_{ij}} = \frac{\mathrm{Count_{ij}}}{\sum \mathrm{k\ Count_{ik}}}, \qquad \mathrm{IDF_i} = \log \frac{\mathrm{N}}{\sum \mathrm{j\ min\ (1\ ,Count_{ij})}} \quad (7)$$

$$\mathrm{TF-\ IDF_{ij}} = \mathrm{TF_{ij}\ .IDF_i} \quad (8)$$

$$\mathrm{CIDEr_n(c,R)} = \frac{1}{|\mathrm{R}|}\sum_{\mathrm{r\epsilon R}} \mathrm{S(\upsilon_{c,n}\ ,\upsilon_{r,n})} \quad (9)$$

$$\mathrm{CIDEr(c,R)} = \frac{1}{\mathrm{N}}\sum_{\mathrm{n=1}}^{\mathrm{N}} \mathrm{w_n.\ CIDEr_n(c,R)} \quad (10)$$

Denklem (7)'deki $Count_{ij}$, *j* açıklamasındaki *i* n-gram'ının sayısıdır. $\sum k\ Count_{ik}$, *j* açıklamasındaki tüm n-gram'ların toplam sayısıdır. *N*, referans açıklamanın tamamının sayısıdır. $\sum k\ Count_{ik}$, referans açıklamanın kaç adet i n-gram içerdiğini belirtir.
Denklem (8)'de $TF-\ IDF_{ij}$, j açıklamasında *i* n-gram için ağırlık hesaplaması yapılır. Bir $\upsilon_{j,n}$ vektörü *n* uzunluğundaki n-gramlar ve *j* açıklaması ile oluşturulur.
Denklem (9)'da $CIDEr_n$, *n* uzunluğundaki n-gramlar için referans ve aday açıklamanın arasındaki kosinüs benzerliğinin tüm referans açıklamalar üzerindeki ortalamasını hesaplar. *R* referans açıklamaların bir kümesidir. |*R*| referans açıklamaların sayısını, *S* kosinüs benzerliğini, $\upsilon_{c,n}$ ve $\upsilon_{r,n}$ aday ve referans açıklamaların vektörlerini temsil eder.
Denklem (10)'da *CIDEr* değeri, farklı n-gram uzunlukları için $\mathrm{CIDEr_n}$ değerlerinin ağırlıklı ortalamasıdır.

Recall-Oriented Understudy for Gisting Evaluation- Longest Common Subsequence (ROUGE-L) [35] metriği otomatik özetleme için geliştirilmiştir. Referans dizi ile aday dizi arasındaki en uzun ortak alt diziyi ölçer. Bu metrik değerinin yüksek olması iyi sonuç alındığının göstergesidir. Hesaplamada kesinlik ve duyarlılık kullanılır. Aşağıdaki matematiksel ifadede ROUGE-L metriğinin hesaplanması gösterilmiştir.

$$\mathrm{P} = \frac{\mathrm{LCS(X,Y)}}{\text{length of candidate}}, \ \mathrm{R} = \frac{\mathrm{LCS(X,Y)}}{\text{length of reference}} \quad (11)$$

$$\mathrm{ROUGE-L} = \frac{(1+\beta^2)\mathrm{PR}}{\mathrm{R}+\beta^2\mathrm{P}} \quad (12)$$

Denklem (11)'de kesinlik (*P*) ve duyarlılık (*R*) değerleri hesaplanır. $LCS(X,Y)$, *X* ve *Y* değerlerinin en uzun

ortak küme uzunluğunu belirtir. β parametresi, kesinlik ve duyarlılık arasındaki önemi belirleyen bir hiperparametredir.

Web ve Mobil Uygulama Entegrasyonu: Bu proje, radyolojik görüntülerin işlenmesi ve tıbbi raporların otomatik üretim sürecinin optimize edilmesini amaçlamaktadır. Proje kapsamında, kullanıcıların radyolojik görüntüleri yükleyebileceği, bu görüntülerden elde edilen bulgulara erişim sağlayabileceği ve detaylı raporları inceleyebileceği bir sistem geliştirilir. Projenin temel bileşenleri arasında arka uç (backend) geliştirme, model servisleri ve mobil ile web tabanlı uygulamalar yer alır. Bu bileşenlerin entegrasyonu yoluyla kullanıcı deneyimi iyileştirilmekte; böylece tıbbi süreçlerin daha verimli ve etkili bir şekilde yönetilmesi hedeflenmektedir.

Projenin arka uç (backend) kısmı, FastAPI, Python tip ipuçlarını temel alan modern ve esnek bir API oluşturma web çerçevesidir [36]. Geliştirilmesi planlanan API, kullanıcıların sisteme radyolojik görüntüleri yüklemelerine, bu görüntülerden elde edilen sonuçları almalarına ve raporları görüntülemelerine olanak tanır. Radyolojik görüntülerden rapor üretimi yapan derin öğrenme modeli, FastAPI [36]üzerinden RESTful API olarak sunulur. API, kullanıcıların işlemlerinin standart bir formatta gerçekleştirilmesini sağlamak amacıyla, JSON (JavaScript Object Notation) formatında üretilen rapor metnini mobil veya web arayüzüne aktarır.

Kullanıcı arayüzü açısından hem mobil hem de web uygulamaları geliştirilmesi planlanmaktadır. Mobil uygulama geliştirme sürecinde Flutter çerçevesi kullanılır, Flutter çok platformlu IOS ve Android için mobil uygulamalar geliştirmeye yarayan açık kaynaklı bir yazılımdır[37]. Kullanıcılar, iOS ve Android platformları üzerinden sisteme erişim sağlayabilir. Bu uygulama, kullanıcıların radyolojik görüntüleri yüklemesini ve ilgili raporların incelenmesini kolaylaştırarak, tıbbi sürecin daha erişilebilir ve kullanıcı dostu hale gelmesine katkı sağlar.

Web arayüzünün geliştirilmesinde React framework'ü tercih edilmektedir. React, dinamik kullanıcı arayüzleri ve tasarımları oluşturmak amacıyla kullanılan bileşen tabanlı, açık kaynaklı bir yazılımdır [39]. Bu web sitesi, kullanıcıların radyolojik görüntüleri yüklemesine ve sonuç raporlarını görüntülemesine olanak sağlayacak işlevsellik sunmayı amaçlar.Bu yapı hem mobil hem de web platformlarında kullanıcıların radyolojik görüntüleri etkin bir şekilde yönetmelerini ve analiz sonuçlarına hızlı erişim sağlamalarını hedeflemektedir.

Bu araştırma projesi, derin öğrenme, görüntü işleme ve doğal dil işleme yöntemlerinin entegre bir biçimde kullanılması yoluyla, radyolojik görüntülerden doğru ve anlamlı raporlar üretilmesini amaçlamaktadır. Kullanılan tüm yöntemlerin, proje hedeflerine ulaşmadaki uygunluğu literatür ve önceki çalışmalarla desteklenmiştir.

3 PROJE YÖNETİMİ

3.1 İş- Zaman Çizelgesi

Araştırma önerisinde yer alacak başlıca iş paketleri ve hedefleri, her bir iş paketinin hangi sürede gerçekleştirileceği, başarı ölçütü ve araştırmanın başarısına katkısı "İş-Zaman Çizelgesi" doldurularak verilir. Literatür taraması, gelişme ve sonuç raporu hazırlama aşamaları, araştırma sonuçlarının paylaşımı, makale yazımı ve malzeme alımı ayrı birer iş paketi olarak gösterilmemelidir.
Başarı ölçütü olarak her bir iş paketinin hangi kriterleri sağladığında başarılı sayılacağı açıklanır. Başarı ölçütü, ölçülebilir ve izlenebilir nitelikte olacak şekilde nicel veya nitel ölçütlerle (ifade, sayı, yüzde, vb.) belirtilir.

İŞ-ZAMAN ÇİZELGESİ (*)

İP No	İş Paketlerinin Adı ve Hedefleri	Kim(ler) Tarafından Gerçekleştirileceği	Zaman Aralığı (..-.. Ay)	Başarı Ölçütü ve Projenin Başarısına Katkısı
1	Veri setinde ön işlem yapılması	Proje Yürütücüsü	1 Ay	Çalışmada kullanılacak olan veri setinde görsellerin boyutu düzenlenecek ve metinler ön işlemden geçirilecektir. %20
2	CNN modelleri ile görüntülerden özellik çıkarımının yapılması	Proje Ekibi	2 Ay	LLM modelini eğitmek için VGG19 ve ResNet50 mimarileri kullanılarak görsellerden özellik çıkarımı yapılacaktır. %20
3	LLM modellerini kullanarak radyoloji raporlarının oluşturulması	Proje Ekibi	2 Ay	Radyoloji görüntülerinden çıkarılan özellikler ve veri setindeki metin raporları ile ClinicalGPT ve ClinicalBERT modellerinin eğitimi gerçekleştirilecek ve rapor üretmeleri sağlanacaktır. %50
4	Eğitilen modellerin başarı performanslarının karşılaştırılması ve modelin yazılım uygulamaları ile entegrasyonu	Proje Ekibi ve Danışman	1-2 Ay	Oluşturulan modeller performans metrikleri kullanılarak karşılaştırılacak ve en yüksek başarıyı gösteren model kullanılarak web ve mobil arayüzü oluşturulacaktır. %10

(*) Çizelgedeki satırlar ve sütunlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

3.2 Risk Yönetimi

Araştırmanın başarısını olumsuz yönde etkileyebilecek riskler ve bu risklerle karşılaşıldığında araştırmanın başarıyla yürütülmesini sağlamak için alınacak tedbirler (B Planı) ilgili iş paketleri belirtilerek ana hatlarıyla aşağıdaki Risk Yönetimi Tablosu'nda ifade edilir. B planlarının uygulanması araştırmanın temel hedeflerinden sapmaya yol açmamalıdır.

RİSK YÖNETİMİ TABLOSU*

İP No	En Önemli Riskler	Risk Yönetimi (B Planı)
1	Veri setinin uygun olmaması veya yetersiz olması.	MIMIC-CXR veri seti kullanılacaktır.
2	Görüntülerden özellik çıkarımı sonrasında modelin eğitim verilerinde çok iyi sonuç gösterip yeni gelen verilerde başarısız sonuçlar göstermesi veya eğitim verilerinde ve test verilerinde başarısız sonuçlar göstermesi.	Görüntülerden özellik çıkarımında kullanılan CNN modellerinin yapısında değişiklikler yapılacaktır.
3	Kullanılan NLP modellerinin yapılan çalışmaya uyumluluk sorunu göstermesi.	Rapor oluşturma bölümünde Transformer modeli olarak GPT2 veya BioClinicalBERT kullanılacaktır.
4	Modellerin yazılım ortamına entegrasyonu sırasında uyumsuzluk veya performans düşüklüğü yaşanması.	Optimize edilmiş model dönüşümleri ve performans iyileştirmeleri yapılacaktır.

(*) Tablodaki satırlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

3.3. Araştırma Olanakları

Bu bölümde projenin yürütüleceği kurum ve kuruluşlarda var olan ve projede kullanılacak olan altyapı/ekipman (laboratuvar, araç, makine-teçhizat, vb.) olanakları belirtilir.

ARAŞTIRMA OLANAKLARI TABLOSU (*)

Kuruluşta Bulunan Altyapı/Ekipman Türü, Modeli (Laboratuvar, Araç, Makine-Teçhizat, vb.)	**Projede Kullanım Amacı**
Yüksek Başarımlı Hesaplama Laboratuvarı	Makine Öğrenmesi modellerinin eğitim aşamasında kullanılacaktır.
Derin Öğrenme modelleri için iş istasyonu	Makine Öğrenmesi modellerinin eğitim aşamasında kullanılacaktır.

(*) Tablodaki satırlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

4. YAYGIN ETKİ

Önerilen çalışma başarıyla gerçekleştirildiği takdirde araştırmadan elde edilmesi öngörülen ve beklenen yaygın etkilerin neler olabileceği, diğer bir ifadeyle yapılan araştırmadan ne gibi çıktı, sonuç ve etkilerin elde edileceği aşağıdaki tabloda verilir.

ARAŞTIRMA ÖNERİSİNDEN BEKLENEN YAYGIN ETKİ TABLOSU

Yaygın Etki Türleri	**Önerilen Araştırmadan Beklenen Çıktı, Sonuç ve Etkiler**
Bilimsel/Akademik (Makale, Bildiri, Kitap Bölümü, Kitap)	Çalışma kapsamında bir adet uluslararası bildiri ve 1 adet ulusal makale çalışması yapılacaktır.

Ekonomik/Ticari/Sosyal (Ürün, Prototip, Patent, Faydalı Model, Üretim İzni, Çeşit Tescili, Spin-off/Start- up Şirket, Görsel/İşitsel Arşiv, Envanter/Veri Tabanı/Belgeleme Üretimi, Telife Konu Olan Eser, Medyada Yer Alma, Fuar, Proje Pazarı, Çalıştay, Eğitim vb. Bilimsel Etkinlik, Proje Sonuçlarını Kullanacak Kurum/Kuruluş, vb. diğer yaygın etkiler)	Mobil ve web arayüzü ile radyolojik görüntülerin yorumlanması yapılacağından model ticarileştirilebilir ve yüksek başarılar elde ettiğinde ticari bir yaygın etki sunabilmektedir.
Araştırmacı Yetiştirilmesi ve Yeni Proje(ler) Oluşturma (Yüksek Lisans/Doktora Tezi, Ulusal/Uluslararası Yeni Proje)	Bu projede görev alan iki lisans öğrencisinin lisans bitirme tezi tamamlanmış olacaktır.

5. BÜTÇE TALEP ÇİZELGESİ

Bütçe Türü	Talep Edilen Bütçe Miktarı (TL)	Talep Gerekçesi
Sarf Malzeme		
Makina/Teçhizat (Demirbaş)	4.000	Yüksek boyutlu verilerin hesaplamaları için bilgisayar RAM donanımı sağlanması
Hizmet Alımı		
Ulaşım	5.000	Uluslararası bildiride ulaşım ve konaklama ücretinin sağlanması
TOPLAM	9.000	

NOT: Bütçe talebiniz olması halinde hem bu tablonun hem de TÜBİTAK Yönetim Bilgi Sistemi (TYBS) başvuru ekranında karşınıza gelecek olan bütçe alanlarının doldurulması gerekmektedir. Yukardaki tabloda girilen bütçe kalemlerindeki rakamlar ile, TYBS başvuru ekranındaki rakamlar arasında farklılık olması halinde TYBS ekranındaki veriler dikkate alınır ve başvuru sonrasında değiştirilemez.

6. BELİRTMEK İSTEDİĞİNİZ DİĞER KONULAR

Sadece araştırma önerisinin değerlendirilmesine katkı sağlayabilecek bilgi/veri (grafik, tablo, vb.) eklenebilir.

Proje yürütücüsü ve proje ekibindeki iki üye, Yazılım Mühendisliği son sınıf öğrencisi olup zorunlu stajlarını yapay zeka alanında tamamlayarak bu alanda tecrübe edinmişlerdir. Her iki ekip üyesi, güncel sertifika programlarını takip ederek bilgi ve becerilerini sürekli güncellemektedir. Proje yürütücüsü, Baykar Makine ve Cezeri Yapay Zeka ve Robotik Teknolojileri'nin ortak yürüttüğü bir programda yapay zeka alanında stajını başarıyla tamamlamışken, proje ekibinin diğer üyesi ise İstanbul Bilişim ve Akıllı Kent Teknolojileri A.Ş.'de görüntü işleme alanında zorunlu stajını tamamlamıştır. Lisans eğitimleri boyunca veri madenciliği, makine öğrenmesi, veri bilimi ve yapay zeka dersleri alarak bu alanlarda sağlam bir bilgi birikimi edinmişlerdir. Mezuniyet sonrası her iki üye de görüntü işleme ve doğal dil işleme alanlarında kariyer yapmayı hedeflemekte olup, bu projenin profesyonel gelişimlerine ve sektörde güçlü bir başlangıç yapmalarına katkı sağlayacağı öngörülmektedir. TÜBİTAK tarafından desteklenen bu proje, ekip üyelerinin yapay zeka alanındaki teorik bilgilerini pratiğe dökme ve araştırma alanında yenilikçi bir yaklaşım geliştirmelerine olanak tanıyacaktır. Ayrıca, proje danışmanının sağlıkta yapay zeka alanındaki bilimsel çalışmaları, yüksek lisans ve doktora tezlerini bu alanda tamamlamış olması ve bu alanda ders veriyor oluşu, ekip için karşılaşabilecekleri zorluklarda değerli bir destek sağlayacaktır.

6. EKLER

EK-1: KAYNAKLAR

[1] E. E. Coche, B. Ghaye, J. de Mey, ve P. Duyck, Ed., *Comparative Interpretation of CT and Standard*

Radiography of the Chest. Berlin, Heidelberg: Springer Berlin Heidelberg, 2011. doi: 10.1007/978-3-540-79942-9.

[2] J. Yuan, H. Liao, R. Luo, ve J. Luo, "Automatic Radiology Report Generation Based on Multi-view Image Fusion and Medical Concept Enrichment", 2019, ss. 721-729. doi: 10.1007/978-3-030-32226-7_80.

[3] Y. Zhang, X. Wang, Z. Xu, Q. Yu, A. Yuille, ve D. Xu, "When Radiology Report Generation Meets Knowledge Graph", *Proceedings of the AAAI Conference on Artificial Intelligence*, c. 34, sy 07, ss. 12910-12917, Nis. 2020, doi: 10.1609/aaai.v34i07.6989.

[4] C. Liu, Y. Tian, W. Chen, Y. Song, ve Y. Zhang, "Bootstrapping Large Language Models for Radiology Report Generation", *Proceedings of the AAAI Conference on Artificial Intelligence*, c. 38, sy 17, ss. 18635-18643, Mar. 2024, doi: 10.1609/aaai.v38i17.29826.

[5] J. Zhang *vd.*, "Hierarchical medical image report adversarial generation with hybrid discriminator", *Artif Intell Med*, c. 151, s. 102846, May. 2024, doi: 10.1016/j.artmed.2024.102846.

[6] "iu_xray.zip - Google Drive". Erişim: 19 Ekim 2024. [Çevrimiçi]. Erişim adresi: https://drive.google.com/file/d/1c0BXEuDy8Cmm2jfN0YYGkQxFZd2ZIoLg/view

[7] S. Zhang, Q. Han, J. Li, Y. Sun, ve Y. Qin, "A medical report generation method integrating teacher–student model and encoder–decoder network", *Biomed Signal Process Control*, c. 94, s. 106251, Ağu. 2024, doi: 10.1016/j.bspc.2024.106251.

[8] B. Jing, P. Xie, ve E. Xing, "On the Automatic Generation of Medical Imaging Reports", içinde *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, Stroudsburg, PA, USA: Association for Computational Linguistics, 2018, ss. 2577-2586. doi: 10.18653/v1/P18-1240.

[9] K. Simonyan ve A. Zisserman, "Very Deep Convolutional Networks for Large-Scale Image Recognition", Eyl. 2014, [Çevrimiçi]. Erişim adresi: http://arxiv.org/abs/1409.1556

[10] S. Hochreiter ve J. Schmidhuber, "Long Short-Term Memory", *Neural Comput*, c. 9, sy 8, ss. 1735-1780, Kas. 1997, doi: 10.1162/neco.1997.9.8.1735.

[11] Y. Xue *vd.*, "Multimodal Recurrent Model with Attention for Automated Radiology Report Generation", 2018, ss. 457-466. doi: 10.1007/978-3-030-00928-1_52.

[12] X. Wang, Y. Peng, L. Lu, Z. Lu, ve R. M. Summers, "TieNet: Text-Image Embedding Network for Common Thorax Disease Classification and Reporting in Chest X-rays", Oca. 2018, [Çevrimiçi]. Erişim adresi: http://arxiv.org/abs/1801.04334

[13] K. He, X. Zhang, S. Ren, ve J. Sun, "Deep Residual Learning for Image Recognition", içinde *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, IEEE, Haz. 2016, ss. 770-778. doi: 10.1109/CVPR.2016.90.

[14] O. Alfarghaly, R. Khaled, A. Elkorany, M. Helal, ve A. Fahmy, "Automated radiology report generation using conditioned transformers", *Inform Med Unlocked*, c. 24, s. 100557, 2021, doi: 10.1016/j.imu.2021.100557.

[15] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, ve I. Sutskever, "Language Models are Unsupervised Multitask Learners". [Çevrimiçi]. Erişim adresi: https://github.com/codelucas/newspaper

[16] N. Kaur ve A. Mittal, "RadioBERT: A deep learning-based system for medical report generation from chest X-ray images using contextual embeddings", *J Biomed Inform*, c. 135, s. 104220, Kas. 2022, doi: 10.1016/j.jbi.2022.104220.

[17] J. Devlin, M.-W. Chang, K. Lee, ve K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding", Eki. 2018, [Çevrimiçi]. Erişim adresi: http://arxiv.org/abs/1810.04805

[18] J. Lee *vd.*, "BioBERT: a pre-trained biomedical language representation model for biomedical text mining", *Bioinformatics*, c. 36, sy 4, ss. 1234-1240, Şub. 2020, doi: 10.1093/bioinformatics/btz682.

[19] E. Alsentzer *vd.*, "Publicly Available Clinical BERT Embeddings", Nis. 2019, Erişim: 21 Ekim 2024. [Çevrimiçi]. Erişim adresi: https://arxiv.org/abs/1904.03323v3

[20] V. Sanh, L. Debut, J. Chaumond, ve T. Wolf, "DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter", Eki. 2019, [Çevrimiçi]. Erişim adresi: http://arxiv.org/abs/1910.01108

[21] M. Sirshar, M. F. K. Paracha, M. U. Akram, N. S. Alghamdi, S. Z. Y. Zaidi, ve T. Fatima, "Attention based automated radiology report generation using CNN and LSTM", *PLoS One*, c. 17, sy 1, s. e0262209, Oca. 2022, doi: 10.1371/journal.pone.0262209.

[22] H. Tsaniya, C. Fatichah, ve N. Suciati, "Automatic Radiology Report Generator Using Transformer With Contrast-Based Image Enhancement", *IEEE Access*, c. 12, ss. 25429-25442, 2024, doi: 10.1109/ACCESS.2024.3364373.

[23] P. Divya, Y. Sravani, C. Vishnu, C. K. Mohan, ve Y. W. Chen, "Memory Guided Transformer With Spatio-Semantic Visual Extractor for Medical Report Generation", *IEEE J Biomed Health Inform*, c. 28, sy 5, ss. 3079-3089, May. 2024, doi: 10.1109/JBHI.2024.3371894.

[24] G. Sapunov, M. S. Burtsev, ve G. V Sapunov, "Memory Transformer", doi: 10.48550/arXiv.2006.11527.

[25] A. Vaswani *vd.*, "Attention Is All You Need", Haz. 2017, [Çevrimiçi]. Erişim adresi: http://arxiv.org/abs/1706.03762

[26] P. Sloan, P. Clatworthy, E. Simpson, ve M. Mirmehdi, "Automated Radiology Report Generation: A Review of Recent Advances", May. 2024, doi: 10.1109/RBME.2024.3408456.

[27] K. Huang, J. Li, ve J. Altosaar, "ClinicalBERT: Modeling Clinical Notes and Predicting Hospital Readmission", doi: 10.48550/arXiv.1904.05342.

[28] G. Wang, G. Yang, Z. Du, L. Fan, ve X. Li, "ClinicalGPT: Large Language Models Finetuned with Diverse Medical Data and Comprehensive Evaluation", Haz. 2023, [Çevrimiçi]. Erişim adresi:

http://arxiv.org/abs/2306.09968
[29] M. M. A. Monshi, J. Poon, ve V. Chung, “Deep learning in generating radiology reports: A survey”, *Artif Intell Med*, c. 106, s. 101878, Haz. 2020, doi: 10.1016/j.artmed.2020.101878.
[30] “medicalai/ClinicalBERT · Hugging Face”. Erişim: 19 Ekim 2024. [Çevrimiçi]. Erişim adresi: https://huggingface.co/medicalai/ClinicalBERT
[31] K. Papineni, S. Roukos, T. Ward, ve W.-J. Zhu, “BLEU”, içinde *Proceedings of the 40th Annual Meeting on Association for Computational Linguistics - ACL ’02*, Morristown, NJ, USA: Association for Computational Linguistics, 2001, s. 311. doi: 10.3115/1073083.1073135.
[32] A. Lavie ve A. Agarwal, “METEOR: An automatic metric for MT evaluation with high levels of correlation with human judgments”, 2007. [Çevrimiçi]. Erişim adresi: https://www.researchgate.net/publication/228346240
[33] G. Reale-Nosei, E. Amador-Domínguez, ve E. Serrano, “From vision to text: A comprehensive review of natural image captioning in medical diagnosis and radiology report generation”, *Med Image Anal*, c. 97, s. 103264, Eki. 2024, doi: 10.1016/j.media.2024.103264.
[34] R. Vedantam, C. L. Zitnick, ve D. Parikh, “CIDEr: Consensus-based image description evaluation”, içinde *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, IEEE, Haz. 2015, ss. 4566-4575. doi: 10.1109/CVPR.2015.7299087.
[35] C.-Y. Lin, “ROUGE: A Package for Automatic Evaluation of Summaries”.
[36] “FastAPI”. Erişim: 21 Ekim 2024. [Çevrimiçi]. Erişim adresi: https://fastapi.tiangolo.com/
[37] “Docs | Flutter”. Erişim: 19 Ekim 2024. [Çevrimiçi]. Erişim adresi: https://docs.flutter.dev/